

补充数据集介绍：Alljoined 系列

实验范式、预处理、论文内分析与数据集结构（详稿，可读版）

（与《六篇文章 _ 六数据集综述》及 EEG-图像方向综述配套；正文编译本文件即可）

2026 年 4 月 8 日

摘要

主综述《六篇文章 _ 六数据集综述》已系统覆盖 THINGS-EEG、MSS、CrossPT、Perceive/Imagine、NOD、Gifford 等六套资源；**Alljoined** 则是近年专门把「脑电—自然图像」推向 **EEG-to-Image 解码/重建**，并分别探索 **实验室级信噪比 + NSD 场景图像** (Alljoined1) 与 **消费级硬件 + THINGS 百万试次规模** (Alljoined-1.6M) 的两条路线。本文按「为什么要这样设计 → 数据里到底有什么 → 论文做了哪些验证 → 你读表/做实验时容易误会什么」的顺序重写，避免只堆名词、话说到一半就停。具体数值以论文版本为准；若与后续正式发表稿不一致，以期刊或最新 arXiv 为准。

目录

1 本文档怎么用、和主综述什么关系	3
2 Alljoined1 (arXiv:2404.05553)	3
2.1 论文在解决什么问题	3
2.2 和以往 EEG-图像数据集相比，作者最想纠正什么	3
2.3 被试、伦理与样本局限	4
2.4 刺激从哪来：NSD 与 shared1000 子集	4
2.5 范式怎样跑：session、block、重复与任务	4
2.6 硬件与显示环境	5
2.7 预处理：作者在做什么、你为什么要在自己实验里对齐	5
2.8 论文里的分析在证明什么	5
2.8.1 ERP 与地形图：先看「有没有像样的视觉响应」	5
2.8.2 SNR 与 SME：为什么「多 session 拼在一起 SNR 变低」反而是好事	5
2.8.3 设计讨论：300+300 ms 到底在争什么	6
2.9 数据与代码去哪找	6
3 Alljoined-1.6M (arXiv:2508.18571)	6
3.1 论文在解决什么问题：把「实验室特权」换成「真实世界可部署」	6
3.2 三条贡献怎样串成一条故事线	6
3.3 被试怎么来、为什么还带两份问卷	6
3.4 采集环境与同步：消费级设备的「额外功课」	7

目录	2
3.5 范式: RSVP + 与 THINGS-EEG2 同构的划分	7
3.6 「1.6M」和每人试次数怎么对得上	7
3.7 预处理: 为什么要重采样到 250 Hz、MVNN 为何只在训练上拟合	7
3.8 七类 meta-category: 给「粗粒度科学问题」开的侧门	8
3.9 论文里的分析在证明什么	8
3.9.1 ERP 与聚类检验: 便宜硬件里还有没有类别信息	8
3.9.2 成对 LDA 与时间分辨 AUC: 轻量基线的重要性	8
3.9.3 EEG-to-Image: 表上的数字下降 任务不可能	8
3.9.4 显著性图: 模型「在看哪里、看什么时候」	8
3.9.5 Scaling 与通道消融: 钱和数据哪个更关键	9
3.10 发布渠道与下载建议	9
4 和主综述六套数据并置时, 怎样比较才不冤枉谁	9
5 本地 PDF 与 BibTeX	10

1 本文档怎么用、和主综述什么关系

若你正在写开题、组会或论文的 数据集/相关工作一节，可以把主综述当作「六套经典数据的横向比较框架」，把本文当作 **Alljoined** 专章：它回答的问题不是「又有多少人多少通道」，而是 **Alljoined** 想解决哪一类缺口，以及 **Alljoined1** 与 **Alljoined-1.6M** 两条线各自适合支撑什么论点。

主文件 六篇文章 _ 六数据集综述.tex 仍以 THINGS-EEG、MSS、CrossPT、Perceive/Imagine、NOD、Gifford 为骨架；本文不重复那六套的细节，只在最后一节用一张对照表说明 Alljoined 与 THINGS-EEG2 (Gifford 等) 并置时，**哪些维度可以比、哪些维度不能硬比**。若你希望把本文并入主 TeX，可删去本文件的导言区与 `\begin{document}`/`\end{document}`，改为 `\input{补充数据集介绍}` 引入正文（需自行处理标题层级是否与主文冲突）。

关于 IDE 报错：若在 Cursor 中出现 `Append data exceeds maximum size of 52428800 bytes`，通常是工具试图把**超大 PDF 全文**塞进对话上下文所致，并不表示你的 .tex 损坏。查论文公式与图注时，请**本地打开 PDF**，或打开 arXiv 的 **HTML 实验版**页面检索关键词。

2 Alljoined1 (arXiv:2404.05553)

2.1 论文在解决什么问题

Alljoined1 的标题写得很直白：它是为 **EEG-to-Image decoding**（从脑电侧恢复或匹配所见图像信息）准备的数据资源。作者先交代一个背景：fMRI 领域已经用「超大规模自然图像 + 深度学习」把 脑活动 → 图像推得很远，但 fMRI 设备昂贵、场景受限；EEG 虽然时间分辨率高、适合实时与便携应用，却长期缺少**同时满足**「自然图像覆盖面大、实验设计少混淆、预处理可复现」的公开数据。于是 Alljoined1 的定位是：用**研究级 EEG** 先把这一条链路的数据质量与范式设计做扎实，让后续模型论文不容易被质疑「靠 block 结构作弊」或「只在几十类玩具图上打转」。

论文信息入口：[arXiv:2404.05553](https://arxiv.org/abs/2404.05553)；全文 PDF：arxiv.org/pdf/2404.05553.pdf；便于检索的 HTML：arxiv.org/html/2404.05553v3。题名在 arXiv 上写作 *Alljoined1 - A dataset for EEG-to-Image decoding*。

2.2 和以往 EEG-图像数据集相比，作者最想纠正什么

这里要用一句话说透「Related Work 在吵什么」：不少 EEG-图像工作的高分重建，依赖 **block 设计**——同一块里连续放同一类别的图。这样做在工程上往往能提高分类或重建分数，却可能引入**与具体图像无关**的捷径：模型只要学会「这一块整体漂移、低频成分、任务节奏」，就能部分预测标签，而不需要真正编码每张图的细粒度视觉信息。Li 等关于 block EEG 实验混淆的讨论，就是在打这个痛点。

Alljoined1 的应对策略可以概括成：**block 仍然存在（便于实验组织），但 block 内的图像从大范围自然图像池中随机抽取**，从而削弱「块级伪信号」与「类别块」之间的锁死关系。与此同时，作者强调刺激来自 MS-COCO 语义体系，每人约一万张量级的自然场景，比「十几个类别、每类固定几张图」的数据集更接近连续语义空间；这和「重建模型只会按类生成」的风险是对着写的——数据侧先保证你**有资格**去谈细粒度重建。

[2] (未找到原文)
文本: '刺激从哪来: NSD 与 shared1000 集'
注释: [摘要] 未对 NSD 和 shared1000 子集进行详细介绍, 可能使读者不清楚刺激的来源。

[9] (未找到原文)
文本: '2.4 刺激从哪来: NSD 与 shared1000 集'
注释: [排版] 章节标题格式不一致, 'NSD'与'shared1000'之间应使用空格分隔。

[12] (未找到原文)
文本: '范式怎样跑: 、 、 重复与任务'
注释: [结构] 孤立子节: 该章节没有父级清晰标题且标题自身信息不完整, 可能导致理解和导航困难

照轴是 **RSVP (快速串行呈现)**: THINGS-EEG1/2 用更短呈现与间隔换吞吐科学上有其价值, 但论文引用文献指出, 分类解码的有效信息有时出现在几百毫秒窗太短, ERP 上较晚的成分可能被截断或与前后 trial 重叠更难分离。Alljoined1 **100 ms 图像 + 300 ms 黑屏**的节奏: 仍然保持较高呈现频率, 但给视觉加工与后续更完整的时间窗。读者可以把这理解成「在吞吐与可解释时间进程之间的折中」, 「Alljoined1 比 THINGS 更好」——**研究问题不同, 取舍就不同。**

伦理与样本局限

10 名被试, 平均年龄约 22 岁 (论文报告均值与标准差), 以右利手、视力正常或矫正视力为主。伦理方面由当地 Research Ethics Board 批准并签署知情同意。论文中未提及如性别比例不平衡、年龄跨度小、部分被试报告精神健康史等。这是后续机器学习工作: **跨人群泛化**在本文数据上并未被验证, 写论文或加实验。

[1] [摘要] 缺少对实验被试数量和年龄等关键信息的明确解释, 可能影响理解。

哪来: NSD 与 shared1000 子集

Alljoined1 的图像不是作者随意爬图, 而是与 fMRI 领域著名的 **Natural Scenes Dataset (NSD)** 对齐: NSD 的刺激来自 MS-COCO, 带物体与类别标注, 便于和大量视觉模型、fMRI 工作衔接。具体地, 作者从 NSD 的 **shared1000** 子集中取出**前 960 张**作为本研究的刺激池。**shared1000 的本意是「在原始 NSD 里经过策划、所有 fMRI 被试都看过的千张共享图」;** Alljoined1 取其中 960 张, 是在可承受采集成本下, 仍然保持**场景多样性 + 可重复性**。论文还统计了 supercategory (如 person、animal、vehicle) 的占比, 提醒读者: 这不 ImageNet, **类别先验本身会进入 EEG 分布**, 做生成模型时要注意与训练图像先验区分。

[5] [内容] 关键概念 shared1000 有简要描述, 但 NSD 缺少详细解释, 可能对读者理解有所影响

2.5 范式怎样跑: session、block、重复与任务

被试在多个**约一小时的 session** 中完成实验。每个 session 有 16 个 block, 结构是「前 8 个 block 与后 8 个 block 成对重复」: **图像集合相同, 顺序重新洗牌**。这样做的目的很实在——同一批图测两遍, 可以**估计可重复性、做 trial 剔除、提高叠加平均的 SNR**, 同时洗牌又减轻「被试记住序列」带来的预期效应。

在每个 block 内, 120 张 NSD 图各呈现 **2 次**, 并穿插 24 个 oddball, 合计 264 trials。单 trial 的时间结构是: 图呈现 **300 ms**, 随后 **300 ms 黑屏**, **屏幕上始终有白色注视十字**; trial 末尾再加 **0–50 ms 的随机 jitter**。jitter 的作用需要向非电生理读者解释清楚: 节律周期化, 大脑低频振荡容易与刺激节奏**相位锁定**, 你会分不清看到的是「对内容」还是「对节律的反应」; 加一点随机延迟, 还能减少被试对下一帧 onset 的精确预期, 减少**预期性电位污染**。

[3] [内容] 缺少对刺激呈现时长的详细解释, 特别是对于图像呈现与黑屏的时长区分

被试任务设计成与「图像内容正交」的注意维持: 当**连续两个 trial 的图像相同时按空格**。这样 oddball 试次在分析中被丢弃 (论文说明包括按键相关运动、重复抑制等混杂), 但实验过程中被试仍需持续盯屏。通过 block 内双次呈现与跨 block 重复, 单张 NSD 图像理论上可累积到 **4 次重复测量**, 这是后面 ERP/SNR 分析敢于声称「信号稳定」的基础之一。

2.6 硬件与显示环境

EEG 使用 BioSemi ActiveTwo, 64 导, 采样率 512 Hz, 24-bit 量化, 实际 10–20 系统; 论文要求电极偏移维持在 40 mV 以下。显示为约 22 英寸、1080 器, 视距约 80 cm, 图像视角约 3.5°。缩小视角是为了控制眼跳幅度与视网膜位对 EEG 视觉研究是常规操作, 否则「同一张图」在不同 trial 上落在视网膜不同觉成分会抖。

[4] [内容] 采集设备的说明缺乏对设备名称、通道数、采样率的详细说明, 尽管已简略提及。
[7] [语言] ‘抖’这一类口语化表述在学术文中可换成‘偏移’或‘位置变化’, 以增强专业性

：作者在做什么、你为什么要在自己实验里对齐
法部分强调「最小必要处理」, 逻辑是: 预处理不是炫技清单, 而是把可解释的中枢活动从眨眼、肌电、坏导联里救出来。流程在 MNE-Python 中实现, 主要步骤建议读者对照自己的管线逐条检查是否一致, 否则跨论文比较数值会失真:

–125 Hz (FIR overlap-add), 再 50/60 Hz 陷波去工频。
保留约 95% 方差不齐子空间, 剔除眨眼等成分。
从刺激 onset 前 –50 ms 到 trial 结束 600 ms (与 300+300 ms 的刺激结构一致), 本句今 sutter 段。

ect: 按通道峰–峰值检测坏 trial, 可插值或删除; 论文报告人均剔除 epoch 的均差 (量级约百次, 具体以原文为准)。
; 基线校正窗口 –50–0 ms, 符合常见 ERP 基线惯例。

的分析在证明什么
与地形图: 先看「有没有像样的视觉响应」
深度学习重建之前, 作者用经典 ERP 与地形图回答一个底线问题: 这群数据里、符合解剖常识的视觉诱发活动? 结果显示, 大约在 150 ms 后出现持续增强, 达峰, 高幅活动可延续到约 500 ms, 之后一致回落。地形图上, 枕–顶区偏正、的模式在单人单次 session 与群体平均上都能对上。这说明数据不是「噪声里找幻某解码模型完全只用到 50 ms 以前的成分, 读者就要问: 那和论文里观测到的主要能量是否一致?

2.8.2 SNR 与 SME: 为什么「多 session 拼在一起 SNR 变低」反而是好事

作者用 Luck 等发展的 Standardized Measurement Error (SME) 来估计噪声, 再定义 SNR, 并强调可以在每个被试、每个电极上给出质量分数。这里最容易被误读的是: 把不同 session 拼起来后, 曲线上的 SNR 数值可能比单次 session 更低。论文的解释是——这不是采集坏了, 而是 trial 更多、跨天变异进入分母后, 噪声估计更保守、更真实; 单次 session 的 SNR 曲线反而波动大, 反映「试次少时噪声估计不稳」。读者在汇报自己数据质量时, 可以借鉴这个叙事: 不要只报一个漂亮但不稳的 SNR, 而要说明估计噪声时用了多少重复、是否跨天。

2.8.3 设计讨论：300+300 ms 到底在争什么

作者把 ERP/SNR 的时间结构与 THINGS-EEG1/2 的短呈现设计对照，核心论点是：视觉加工不止早期 feed-forward，后面还有注意、语义、记忆更新等过程；若呈现窗过短，这些成分要么没长出来，要么与相邻 trial 混叠更难分离。也就是说，Alljoined1 的范式选择是**为后续解码窗口留出语义相关潜伏期**，代价是单位时间呈现的图片数低于极限 RSVP。写论文时如果你用 Alljoined1，应在 Methods 里用两三句话把这个 trade-off 说清楚，而不是只写「我们用了 300 ms」。

2.9 数据与代码去哪找

统一入口：linktr.ee/alljoined1。论文写明**原始与预处理 EEG** 均在 OSF 发布，对象文件里带有与 NSD 图像 ID 对应的标签，这样你可以把 EEG trial 精确对齐到 NSD/COCO 的同一文件版本。OSF 链接以论文 Data availability 为准（文中示例：osf.io/kqgs8，若失效请回链表查最新）。刺激与预处理代码见论文 Code availability；若仍指向匿名 GitHub，正式引用时请替换为作者公开仓库。

3 Alljoined-1.6M (arXiv:2508.18571)

3.1 论文在解决什么问题：把「实验室特权」换成「真实世界可部署」

如果说 Alljoined1 是用研究级硬件把「自然图像 EEG-图像」做严谨，Alljoined-1.6M 则换了一个主问题：**消费级、低成本 EEG 能不能撑起语义解码、检索和 EEG-to-Image**？论文给出令人印象深刻的价格数量级对比：Flex 2 整套约 **\$2.2k** 量级，而传统 64 导研究级系统可至 **\$60k** 量级（均为论文估计，随市场波动）。这不是卖设备广告，而是研究动机——若所有公开大数据都来自顶级放大器，BCI 论文就会系统性偏向「实验室可行、落地不可行」。Alljoined-1.6M 想填的，正是**算法在低保真、可普及硬件上到底能走多远**这一空白。

论文入口：[arXiv:2508.18571](https://arxiv.org/abs/2508.18571)；PDF：arxiv.org/pdf/2508.18571.pdf；HTML：arxiv.org/html/2508.18571v2。

3.2 三条贡献怎样串成一条故事线

作者把贡献写成三点，其实是一条链：先放出 **THINGS 倡议框架下、与 THINGS-EEG2 图像划分对齐**的百万试次数据（这样别人无法说「你换了图没法比」）；再在**同一套基准任务**上复现公开方法，给出**可对照的数**；最后问「钱少、SNR 差，能不能用数据量补？」——用 scaling 曲线与通道消融回答。读者若只记一张表，容易断章取义；若记这条链，就能在组会上讲清楚**为什么这个数据集不只是「又大又便宜」**。

数据规模一句话：**20 名被试**，每人 **4 个 session**，合计约 **1.6M 试次**；图像条件为 THINGS 中与 THINGS-EEG2 一致的 **16,740 张训练图 + 200 张测试图**；硬件为 Emotiv Flex 2，**32 通道**。

3.3 被试怎么来、为什么还带两份问卷

被试从旧金山湾区招募，初筛约 48 人，再按**行为成绩与任务投入**选出 20 人完成正式实验——这意味着数据集不是「随便路人」，而是在**任务上相对稳定**的一群；写论文时若把你的算法

与论文基线比较，要说明你是否沿用了同样的筛选逻辑，否则公平性会被质疑。

每位被试做四天、每天约两小时 on-task，中间有休息。作者还发放两类问卷：筛查问卷记录相对稳定特质（病史、神经多样性、知情同意等），session 前问卷记录咖啡因、睡眠、疲劳等**状态变量**。这些元数据随集发布，价值在于：当你发现某天解码异常时，可以回头做**协变量分析**，而不是只会抱怨「深度学习不 work」。

3.4 采集环境与同步：消费级设备的「额外功课」

Flex 2 用 Ag/AgCl 凝胶电极，蓝牙 5.2 流式传输，采样 **256 Hz**。实验在安静暗室进行，视距约 60 cm，视角约 7°，灰背景，PsychoPy 呈现；通过 Emotiv API 打 trigger 对齐图像 onset 与 EEG。无线与消费级固件会带来**丢包**、**trigger 抖动**类问题，论文报告因同步失配丢弃约 **0–0.6%** trial，并称与既往 Emotiv 验证文献同量级——这是在告诉读者：**不是零成本对齐，但作者在数量级上可控**。

3.5 范式：RSVP + 与 THINGS-EEG2 同构的划分

呈现节奏是经典 RSVP：每张图 **100 ms**，接 **100 ms** 空白，即 SOA 约 **200 ms**。刺激来自 THINGS，并且**训练/测试图像与类别互不重叠**，这与 THINGS-EEG2 的设计哲学一致：避免解码器在类别层面「见过答案」。

每个 session 有 **19** 个约 5 分钟的 block。前 **4** 个 block 专门扫过 **200** 张测试图：按论文给出的计数， 4×51 条 RSVP 序列、每条 20 张图，构成每 session **4080** 次与测试相关的呈现。剩下 **15** 个 block 呈现训练图：训练图被分成两半，分别在第 1–2 次访问与第 3–4 次访问中各展示一轮，使每张训练图在跨 session 层面可累积约 **四次**重复；测试图则在每人层面重复约 **80** 次，用于**强力 trial 平均**以对抗噪声。序列随机还有约束：同一图不能紧邻重复，避免 AA/ABA 模式引入人工可解码节奏。

注意任务仍是「正交」的：每序列结束后约 2s 内按键报告是否出现 “Woody” catch（约 6% 试次），用于维持警觉且不绑定某一物体大类。Hugging Face 上还提供刺激呈现录像，方便你核对 trigger 与屏幕是否真的同步。

3.6 「1.6M」和每人试次数怎么对得上

论文给出每人约 $4 \times 20,880 = 83,520$ 次图像 trial，20 人合计约 **1.67M**，与摘要中 “over 1.6 million” 一致。训练图重复约 4–5 次/人、测试图 80 次/人，不是在浪费被试时间，而是为两类分析服务：一是像 THINGS-EEG2 那样做**条件层面的稳健估计**；二是允许你在推理时**对同一图的多次重复做平均**，看 SNR 提升后模型上限在哪里。

3.7 预处理：为什么要重采样到 250 Hz、MVNN 为何只在训练上拟合

原始数据为 .edf，用 MNE-Python 处理；设备固件已带双 50/60 Hz 陷波。Epoch 取 **–200 ms 到 +1000 ms**，基线为刺激前 **200 ms**，并重采样到 **250 Hz**——关键句是：**为了与 THINGS-EEG2 论文中的处理设定对齐**，否则你用 256 Hz、别人用 250 Hz，同一模型的差异可能来自重采样而不是数据本身。

[10] (未找到原文)
文本: '3.9.4 显著性图: 模型「在看哪、看什么时候」'
注释: [排版] 标题格式混乱, '显著性图'后面应该有适当的标点符号以保持一致性。

多元噪声归一化 (MVNN) 按 Guggenmos 等方法实现。作者特别强调: 白噪声在训练划分上估计。这句话必须划重点——若在全体数据上先 MVNN 再划分 train/test 集统计量泄漏进训练, 审稿人若较真会直接判无效。自己做实验时请完全复现。

3.8 七类 meta-category: 给「粗粒度科学问题」开的侧门

THINGS 有 1854 个细类别, 对深度模型是宝藏, 对线性解码或课堂演示有时「太细」。作者把所有 trial 额外标注为 7 个 meta-category (动物、食物/植物、交通工具、工具、家具/家居、身体部位/衣物、玩具/游戏/乐器等), 并保证训练/测试中分布一致。这样做的直接好处是: 你可以先问「大脑能否区分动物 vs 车辆」这种可解释问题, 再逐步过渡到细粒度; 而不是一上来就在 1854 类上画一张好看但不稳定的准确率条。

3.9 论文里的分析在证明什么

3.9.1 ERP 与聚类检验: 便宜硬件里还有没有类别信息

作者叠加约 160 万试次得到群体 ERP, 地形图呈现 RSVP 下枕叶主导、并与 200 ms SOA 相关的周期性成分——这是在视觉上建立「数据里确实有锁相的视觉诱发活动」。进一步对 meta-category 的 ERP 做时空聚类置换检验, 21 对比较中 16 对在 $p < 0.01$ 出现显著簇。读者应这样理解结论: 不是「消费级 EEG 等价于实验室级」, 而是「在作者设定的范式与预处理下, 粗粒度类别信息仍统计显著」——这为后续深度学习提供了先验: 标签不是纯噪声。

3.9.2 成对 LDA 与时间分辨 AUC: 轻量基线的重要性

作者用成对 LDA 沿时间滑动, 计算 hold-out ROC-AUC, 并用聚类检验相对 0.5 机遇水平。显著簇峰值约在 100 ms、220 ms、400 ms, 与 THINGS-EEG2 上类似分析的时间结构形状相近, 但 Alljoined 绝对 AUC 更低。这段结果的最佳读法是: 时间动力学大致还在, 但 SNR 惩罚体现在幅度上; 你若提出一个新模型, 至少应先在同一协议下超过这个 LDA 基线, 再谈架构创新。

3.9.3 EEG-to-Image: 表上的数字下降 任务不可能

论文复现 ENIGMA、ATM-S、Perceptogram 等公开管线, 并在 THINGS-EEG2 与 Alljoined-1.6M 上对照。表 1 摘录核心列。总体模式是: Alljoined-1.6M 上 像素相关、Top-1 检索等指标明显低于 THINGS-EEG2, 但部分高层特征指标差距相对较小; 人类被试对重建图的识别率也仍高于机遇。作者据此讨论: 复杂架构在低保真 EEG 上可能不如更稳健的多被试/相对简单管线, 架构与噪声模型需要为消费级数据重新设计——这不是失败陈述, 而是把「下一步研究空间」钉在纸面上。

3.9.4 显著性图: 模型「在看哪里、看什么时候」

对 ENIGMA 用 Integrated Gradients, 以各类别训练图 CLIP 嵌入均值为目标, 归因结果显示在 160–300 ms、枕区电极有稳定峰值。论文解释这与 RSVP 下早期视觉成分主导一致, 并提示晚期语义在消费级 EEG + 该范式下更难被模型利用。对你而言, 这段分析的价值是: 如

表 1: EEG-图像重建: 论文 Table 1 摘录 (数值以 arXiv:2508.18571v2 为准)

数据集	方法	PixCorr↑	SSIM↑	Top-1↑	人类识别 ↑
THINGS-EEG2	ENIGMA	0.159	0.422	27.60%	83.06%
THINGS-EEG2	ATM-S	0.136	0.392	30.15%	77.14%
THINGS-EEG2	Perceptogram	0.247	0.431	–	79.17%
Alljoined-1.6M	ENIGMA	0.079	0.416	6.00%	65.43%
Alljoined-1.6M	ATM-S	0.090	0.374	0.50%	60.31%
Alljoined-1.6M	Perceptogram	0.094	0.401	–	62.00%

果你声称自己的新架构捕获了「深层语义」，就需要解释它是否真的用到不同于早期枕叶窗口的信息，而不是只换了一个 loss。

3.9.5 Scaling 与通道消融：钱和数据哪个更关键

递增训练子集时，性能随试次在对数坐标下近似线性上升且未饱和，说明继续扩大规模仍有收益；Alljoined 曲线整体低于 THINGS-EEG2，体现 SNR 惩罚。通道削减实验则支持：从 64/32 导往下减，性能会掉，但通道数不是两数据集差距的唯一主因；减到约 24 导后收益递减——这给硬件选型一个粗略结论：不是电极越多越好，但过少也会碰到平台。

3.10 发布渠道与下载建议

数据集: [Huggingface: Alljoined/Alljoined-1.6M](#); 代码与说明: [github.com/Alljoined/Alljoined-1.6M](#); 联系: team@alljoined.com。全量体积极大, 务必先读卡片与 README, 用 `huggingface_hub` 按需下载或流式读取, 不要一上来 `sync` 全盘。

4 和主综述六套数据并置时，怎样比较才不冤枉谁

表 2: Alljoined1 vs Alljoined-1.6M vs THINGS-EEG2: 对照维度 (概念级)

维度	Alljoined1	Alljoined-1.6M	THINGS-EEG2 (参考)
刺激库呈现	NSD shared1000 中 960 张池 300 ms 图 + 300 ms 空屏	THINGS 16,740+200 划分 100 ms 图 + 100 ms 空屏 RSVP	THINGS 同划分 RSVP (见原论文)
硬件最适合讲的故事	BioSemi 64 导, 512 Hz 与 NSD/fMRI 衔接、较长 on-time、抗 block 混淆设计	Emotiv Flex 2, 32 导, 256 Hz 低成本可部署、百万试次 scaling、与 THINGS 基准对齐	研究级 64 导等 编码模型、训练/测试概念分离、高条件数

怎样读这张表才公平：若比较解码准确率或重建指标，必须并列写清 试次是否平均、是否跨 session、MVNN 是否在训练上拟合、模型是否跨被试共享。忽略其中任意一条，数字差异可能来自协议而不是算法。若你的论文主线是 CLIP-扩散条件生成或细粒度检索，Alljoined-1.6M 与 THINGS 体系对齐更省力；若你要把 EEG 结果和 NSD/fMRI 论文对齐，Alljoined1 的刺激索引更自然。

5 本地 PDF 与 $\text{Bib}\text{T}_\text{E}\text{X}$

与本文同目录可离线阅读:Alljoined1_EEG-to-Image_arXiv2404.05553.pdf,Alljoined-1.6M_arXiv2508.18571.pdf
再次提醒: 勿在 Cursor 对话中让工具读取整本大 PDF, 以免触发约 50MB 上下文上限。

```
@misc{xu2024alljoined1,
  title      = {Alljoined1: A dataset for EEG-to-Image decoding},
  author      = {Xu, Jonathan and Aristimunha, Bruno and Feucht, Max Emanuel
                 and Qian, Emma and Liu, Charles and others},
  year        = {2024},
  eprint       = {2404.05553},
  archivePrefix= {arXiv},
  primaryClass = {q-bio.NC},
  url          = {https://arxiv.org/abs/2404.05553}
}

@misc{xu2025alljoined16m,
  title      = {Alljoined-1.6M: A Million-Trial EEG-Image Dataset for
                 Evaluating Affordable Brain-Computer Interfaces},
  author      = {Xu, Jonathan and Bruzadin Nunes, Ugo and Jiang, Wangshu
                 and Ryther, Samuel and Pringle, Jordan and others},
  year        = {2025},
  eprint       = {2508.18571},
  archivePrefix= {arXiv},
  primaryClass = {q-bio.NC},
  url          = {https://arxiv.org/abs/2508.18571}
}
```